

**MEMORIA:**  
**ESTUDIO ESTADÍSTICO SOBRE MODELOS DE DURABILIDAD,**  
**USO Y DESGASTE EN LAS AUTOPISTAS ESPAÑOLAS**

**INTEGRANTES:**

**Lazaro Bertin Victor**

**Villasís Giribets Albert**

**Jaramillo Duarte Ivan Miguel Angel**

**Kaddouri Mammar Mohamed El Mahdi**

**ASIGNATURA:**  
**PROBABILIDAD Y ESTADISTICA**

**FECHA: 12/05/2018**

**SOPORTE BASICO: R-ESTUDIO**

## INTRODUCCION:

El trabajo consiste en realizar un estudio probabilístico del desgaste de las autopistas Españolas, que como ingenieros civiles es un factor muy importante en los proyectos es la vida útil.


Es importante realizar un buen estudio antes de la construcción de una nueva autopista o carretera o para el mantenimiento de estas.

(La durabilidad es el concepto ingenieril que se relaciona con la vida útil, la cual estará condicionada principalmente por factores demográficos entre los puntos de unión de las carretas ya que son obras lineales, en el diseño del proyecto se supone una vida útil concreta.)

Nuestro objetivo principal era poder realizar estimaciones sobre la cantidad de vehículos que circularán en los años a venir, ya que el uso de las infraestructuras viarias es lo que más afecta a su vida útil. Y también observar cómo afecta la temperatura en los tramos estudiados.

El deterioro más frecuente en las mezclas bituminosas es el fallo por fisuración, originado por la fatiga del material (tráfico) y por las variaciones climatológicas (temperaturas, granizos, tormentas...). Este tipo de fallo se inicia a partir de micro fisuras en el material, permitiendo, entre otros posibles daños, la infiltración de agua, debilitando de esta forma la estructura y con elevadas posibilidades de sufrir, a posteriori, severos daños en el firme.


## IRI, CRI, DEFLEXIÓN: (modelos de estudio)



**IRI (índice de regularidad internacional):** regula la forma de la sección transversal del firme, viene condicionado por la demografía de las ciudades que une la autopista, y esto determinará el ancho y cantidad de carriles a la hora del dimensionado del proyecto.

**CRI:** determina la rugosidad del acabado del asfalto, aspecto fundamental sobre la seguridad vial, pensado para evitar riesgos y accidentes, de determinará a partir de las velocidades máximas de circulación permitidas.





**DEFLEXION:** modelo que estudia la parte estructural de un pavimento de circulación, con este modelo se estudian efectos a largo plazo, que ocurren por la acumulación repetida de las cargas producidas por el constante flujo de vehículos, centramos nuestro análisis en este modelo, ya que es el que más afecta a durabilidad de las autopistas.

Variables de estos modelos: cargas, temperaturas y materiales. En cada modelo por separado se cuantifican de forma diferente.

Para la realización de este estudio hemos tomado los datos de 2 autopistas españolas en las estaciones de aforo.

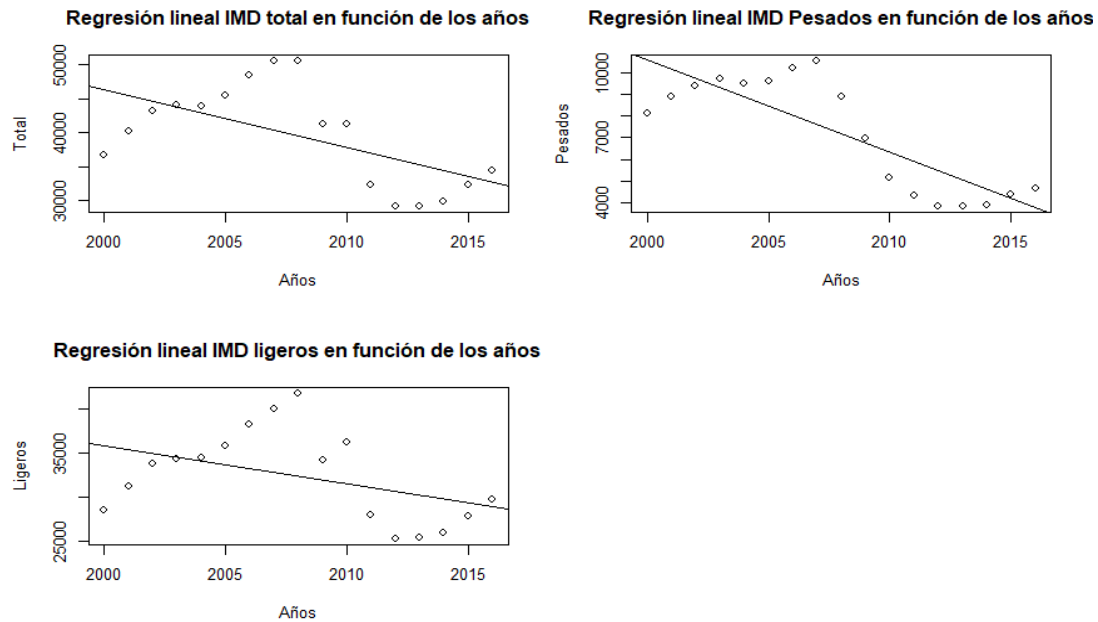
Concretamente la AP-9 en una estación cercana a Santiago de Compostela y la AP-7 norte, cerca de Tarragona. Las cuales son totalmente distintas en el ámbito geográfico y climatológico ya que una se encuentra en el mediterráneo (AP7) e otra en el atlántico (AP9). De esta forma analizaremos de forma estadística la gran diferencia que puede ocurrir de un proyecto a otro.

En primer lugar, vamos a definir las variables que hemos tomado en cuenta. Como variable independiente tenemos los años. Concretamente desde el 2000 al 2016.

Como variables dependientes tomamos el IMD (índice medio diario) de los distintos tipos de vehículos.

Hemos realizado unas regresiones lineales simples para intentar modelizar la variación de la cantidad de vehículos que circulan por estas, y poder realizar estimaciones del IMD a partir del 2016.

Las siguientes graficas son las regresiones lineales que realizamos para el tramo del AP-7.



La conclusión sacada de estos plots es que no se puede representar de forma lineal ya que no existe una tendencia clara. Se ven 3 periodos, que corresponden al periodo antes de la crisis, durante y después. Se puede observar que en el periodo de crisis la cantidad de vehículos disminuye, mientras que normalmente tiende a aumentar.

La foto anterior es una captura de pantalla de la consola de R en la que podemos ver la matriz

```
Años      Años      Pesados      Ligeros      Total
Años      1.0000000 -0.8215093 -0.4241719 -0.5880610
Pesados   -0.8215093  1.0000000  0.7761353  0.8975188
Ligeros   -0.4241719  0.7761353  1.0000000  0.9746608
Total     -0.5880610  0.8975188  0.9746608  1.0000000
> regresion <- lm(Total ~ Años, data = Total)
> summary(regresion)

Call:
lm(formula = Total ~ Años, data = Total)

Residuals:
    Min       1Q   Median       3Q      Max
-9692  -4604    192   3307  11043


Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) 1754663.3   609073.6   2.881  0.0114 *
Años        -854.1      303.3   -2.816  0.0130 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 6127 on 15 degrees of freedom
Multiple R-squared:  0.3458,    Adjusted R-squared:  0.3022
F-statistic: 7.929 on 1 and 15 DF, p-value: 0.01303

> |
```

de correlación entre las distintas variables y el diagnostico de el modelo. Obtenemos una  $R^2=0,3458$  que es un resultado muy bajo ya que este modelo solo explica 34,5% de los datos obtenidos.

Por lo que el modelo adecuado para el estudio de la circulación no es un modelo lineal.



Utilizando el siguiente comando: `"ggplot(Datos, aes(x = Años, y = Pesados)) + geom_point() + geom_smooth(method = "lm", formula = y ~ poly(x,3), level=0.95)"` obtenemos este plot con el que podemos deducir que un modelo que se acercaría más al buscado sería una regresión polinomial de tercer grado. Aumentando el grado del polinomio se obtendría seguramente una mejor  $R^2$  y un modelo mas preciso, pero este modelo parece que ser el más óptimo para predicciones futuras.

El problema resulta ser que al colocar el comando para este modelo no se consigue obtener más que una regresión de orden 2. (ver debajo).

```
> LinearModel.1 <- lm(Pesados ~ Años + I(Años^2)+I(Años^3), data=Datos)
> summary(LinearModel.1)
```

Call:

```
lm(formula = Pesados ~ Años + I(Años^2) + I(Años^3), data = Datos)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-1977.07	-1181.33	-14.68	933.02	2279.22

Coefficients: (1 not defined because of singularities)

	Estimate	Std. Error	t value	Pr(> t )
(Intercept)	-1.149e+08	6.572e+07	-1.748	0.102
Años	1.148e+05	6.546e+04	1.754	0.101
I(Años^2)	-2.870e+01	1.630e+01	-1.761	0.100
I(Años^3)	NA	NA	NA	NA

Residual standard error: 1435 on 14 degrees of freedom

Multiple R-squared: 0.7338, Adjusted R-squared: 0.6958

F-statistic: 19.3 on 2 and 14 DF, p-value: 9.466e-05

El modelo de regresión polinómica de orden 2 nos da una  $R^2$  bastante mejor y un p valor muy bajo, pero tampoco nos sirve para predecir ya que si realizamos una estimación de los años 2017 a 2021 obtenemos.



```
> nuevos.años <- data.frame(Años = seq(2017,2021))
> predict(LinearModel.1, nuevos.años)
```

	1	2	3	4	5
	1730.0441	761.4755	-264.4923	-1347.8591	-2488.6251

Por lo que descartamos estos dos modelos anteriores.

Para obtener un modelo conforme a las estimaciones realizadas por fomento hemos terminado por estudiar el periodo postcrisis, concretamente desde 2013-2016.

En estas graficas observamos el resultado de la regresión lineal simple con los últimos 4 años.



Obtenemos una regresión con pendiente positiva, que coincide con nuestra hipótesis

```

Años    Pesados    Ligeros    Total
Años    1.0000000  0.9626641  0.9764003  0.9757951
Pesados  0.9626641  1.0000000  0.9875490  0.9913575
Ligeros  0.9764003  0.9875490  1.0000000  0.9996515
Total    0.9757951  0.9913575  0.9996515  1.0000000
> RTotol <- lm(Total ~ Años, data = Total)
> summary(RTotol)

call:
lm(formula = Total ~ Años, data = Total)

Residuals:
    1     2     3     4 
491.9 -705.7 -64.3  278.1 

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) -3611967.7   577375.7   -6.256   0.0246 *
Años           1808.6     286.6     6.310   0.0242 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 640.9 on 2 degrees of freedom
Multiple R-squared:  0.9522,    Adjusted R-squared:  0.9283 
F-statistic: 39.82 on 1 and 2 DF,  p-value: 0.0242

```

```

call:
lm(formula = Pesados ~ Años, data = Pesados)

Residuals:
    1     2     3     4 
83.1 -156.3  63.3   9.9 

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) -598926.30  119926.57   -4.994   0.0378 *
Años           299.40     59.53     5.029   0.0373 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 133.1 on 2 degrees of freedom
Multiple R-squared:  0.9267,    Adjusted R-squared:  0.8901 
F-statistic: 25.29 on 1 and 2 DF,  p-value: 0.03734

```

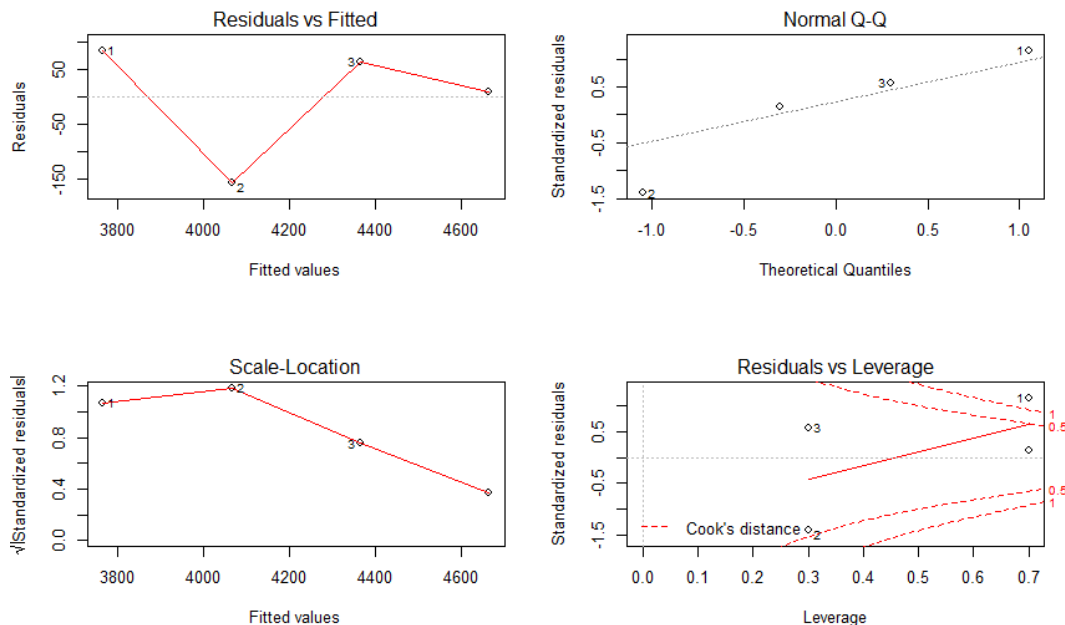
Los  $R^2$  son muy altos, en el primer modelo, que representa a el IMD total respecto los años tenemos 95% explicado y un p-valor bajo. Aunque resulta ser normal debido a la poca cantidad de datos utilizados.

También realizamos la regresión polinómica de orden 2 y realizamos el diagnostico de los modelos para comparar cual es el más adecuado. Evaluaremos los modelos correspondientes

al IMD Pesados, ya que ambas variables tienen un comportamiento similar, nos servirá con estudiar una.

```
Residual standard error: 163.7 on 1 degrees of freedom
Multiple R-squared: 0.9446, Adjusted R-squared: 0.8338
F-statistic: 8.526 on 2 and 1 DF, p-value: 0.2354
```

La  $R^2$  es mejor pero el p-valor también crece. Utilizando el comando plot estudiamos la aleatoriedad, distribución normal, homocedasticidad y los puntos extremos de estos 2 modelos.



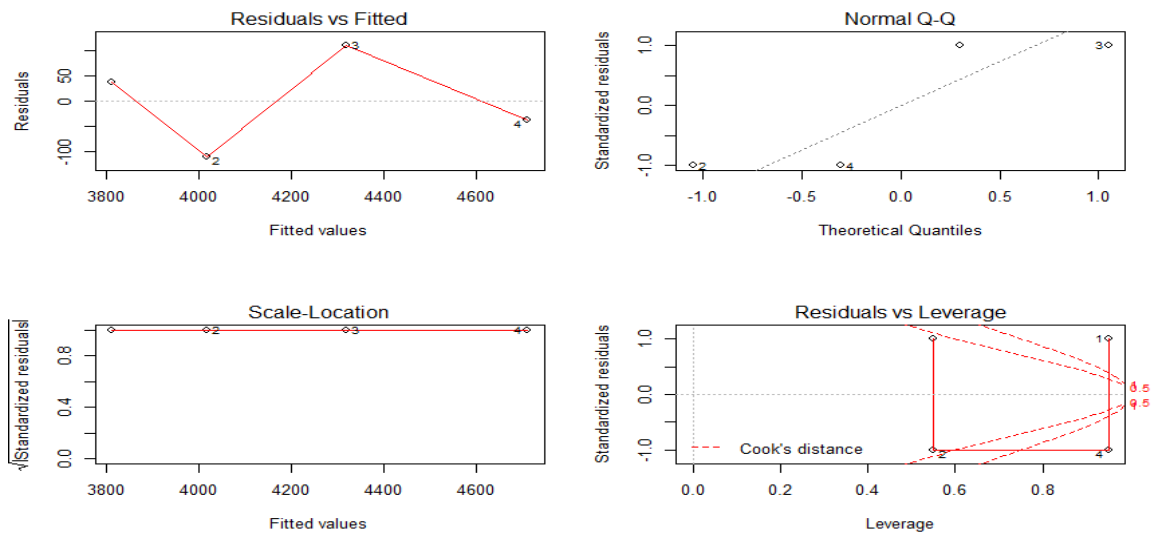
Estos gráficos nos permiten hacer un diagnóstico rápido del método de la regresión lineal simple. Podemos observar que el programa nos dice que tengamos cuidado con los puntos 1 2 y 4 ya que pueden ser los mas problemáticos. En la primera observamos 2 puntos que tienen bastante valor residual respecto la línea imaginaria. Encima la línea que forman no esta muy alineada con respecto la línea imaginaria. Esto es debido a que tenemos muy pocos datos, por lo que es normal que ocurra esto.

Observamos que los puntos parecen seguir una distribución normal menos por el 2 que esta un poco alejado.

En el tercer grafico observamos que hay un cambio de tendencia entre el 1-2 y el 2-3-4. Por lo que el dato numero 1 tiene que ser vigilado.

Y el ultimo grafico nos indica que puntos extremos son los que mas nos afectan a nuestra correlación. El punto 1 esta por fuera del intervalo por lo que debería ser eliminado. No realizaremos tal medida ya que tendríamos aun menos datos y el modelo seria cada vez menos fiable a gran escala.


Realizamos lo mismo con el segundo modelo.



Observamos que en este modelo empeora bastante mas el diagnostico ya que los puntos no parecen seguir una distribución normal. Los valores residuales son mas bajos y se ve una clara tendencia, pero obtenemos 2 puntos críticos que nos afectan mucho a nuestra correlación.

Por lo que el método que utilizamos para las predicciones será con el modelo de la regresión lineal simple.

Realizamos una predicción hasta el 2021 de las dos autopistas para el IMD total y el IMD pesados, los resultados son muy similares. En ambas autopistas observamos que nuestros intervalos de confianza y predicción se van ampliando a medida que avanzan los años. Es debido a los pocos datos que hemos utilizado.



Este modelo de predicción podría ser mejorado con los datos parciales de los años 2017 y 2018, aunque al no tener acceso a estos nos contentamos con realizar la estimación siguiendo este modelo.



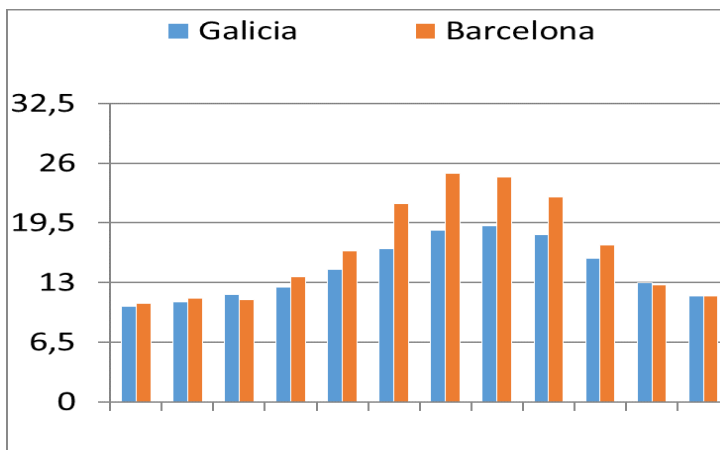
Para el IMD Pesados obtenemos dos tablas.

```
> nuevos.años <- data.frame(Años = seq(2017,2021))
> predict(RPesados, nuevos.años)
      1      2      3      4      5
4963.5 5262.9 5562.3 5861.7 6161.1
```

```
> nuevos.años <- data.frame(Años = seq(2017,2021))
> predict(RPesados2, nuevos.años)
      1      2      3      4      5
5167.5 5360.1 5552.7 5745.3 5937.9
```

La primera captura de pantalla nos muestra la predicción del IMD pesados en el AP-7-N desde el 2017 al 2021. La segunda captura nos muestra las predicciones para el AP-9.

## TEMPERATURA



La presentamos como una variable y no como modelo, de manera informativa, ya que es la segunda causa de degradación más importante del asfalto, después de la estructural, ya que influye en las dilataciones térmicas.

Podemos observar que en la (AP-7) Barcelona, sufrirá más problemas de degradación por dilatación, ya que las temperaturas son mayores

## ECUACION CARACTERISTICA

$$\varepsilon_r = 6,925 \cdot 10^{-3} \cdot N^{-0,27243}$$

$$N = IMD_p \cdot 365 \cdot F \cdot \left( \frac{(1+t)^n - 1}{t} \right)$$

**N:** el número de aplicaciones de carga

**IMD<sub>p</sub>:** Intensidad Media Diaria de vehículos pesados. Para una categoría de tráfico T1, según la norma IC-6.1: 2000 vehículos pesados / día.

**t:** tasa de crecimiento prevista: por defecto, 4%

**n:** horizonte de la vida útil del firme: por defecto, 20 años.



**F:** Coeficiente de equivalencia de los vehículos pesados en número de aplicaciones del eje tipo, obtenido mediante la distribución de cargas por eje: por defecto, 0.5

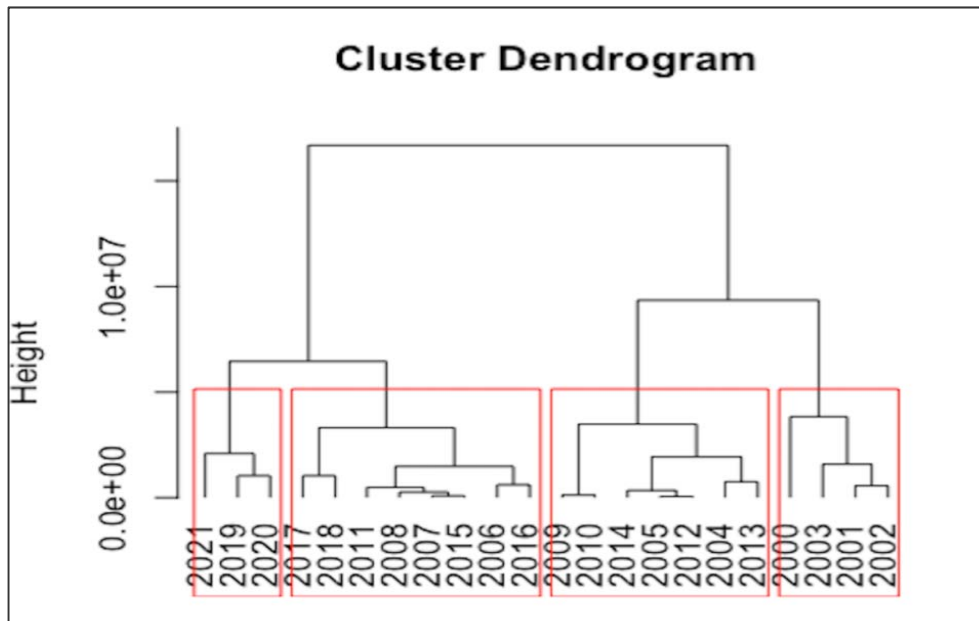
**HIPOTESIS:** aumento de aplicaciones flujo vehicular, esto implica una mayor aplicación de carga y una disminución del límite elástico no lineal.

Mediante rectas de regresión lineal, realizamos una predicción del **IMD<sub>p</sub>**, con este parámetro calculamos el número de aplicaciones de carga, en la ecuación “**N = (IMD<sub>p</sub>)**”.

Este nuevo parámetro, el número de aplicaciones de carga, se modela con la ecuación  $\epsilon_r = (N)$  y nos dará las variaciones de la deformación a lo largo de las aplicaciones de carga anuales, estudiando así el comportamiento del límite elástico.

A continuación vemos gráficamente las variaciones del **IMDp** y  $\epsilon_r = (N)$ .





En este cluster hemos reagrupado en 4 bloques los años en los cuales el flujo de tráfico era muy similar que equivale a decir que el desgaste de las autopistas era muy similar en cada uno de estos bloques. Este cluster nos permite afirmar que no existe linealidad en los datos ya que dentro de cada bloque nos encontramos con años muy dispersos. Es por eso que hemos realizado un modelo de regresión polinómica para así ver una tendencia más clara y precisa de la variación del flujo de tráfico, (aunque hemos terminado por estudiar el periodo postcrisis, concretamente desde 2013-2016 para hacer una estimación de los datos del 2017 al 2021).

## CONCLUSIÓN:

Concluimos entonces que, aunque los modelos utilizados no sean los más precisos debido a la falta de datos, la circulación por las autopistas seguirá creciendo, como lo confirman las estimaciones realizadas por fomento.

La falta de datos es debida a una dispersión muy pronunciada en el tratamiento de los datos, ocurre por la falta de las demás variables que influyen en la durabilidad.

Es decir, no es completo porque faltan variables

Por lo que cada vez las autopistas van a recibir más aplicaciones de carga y sufrirán más fatiga a medida de los años. Se tendrá entonces que realizar más obras de mantenimiento para evitar el deterioro y poder alargar la vida útil de la autopista.

La variable más predominante que falta en el mantenimiento, que influiría gráficamente como un aumento periódico del límite elástico, y una posterior disminución hasta los límites permitidos por normativa, subiendo de nuevo, es decir una función a trozos.

Puede que, en el futuro, si la circulación sigue aumentando se tengan que construir más autopistas para poder gestionar el tráfico y mejorar las condiciones de las actuales para que puedan soportar tal cantidad de cargas.

**El aumento del flujo de tráfico conllevará a una disminución del límite elástico de forma no lineal, necesitando los mantenimientos periódicos requeridos para un buen funcionamiento.**